



TUGAS M2 - DATA MINING



Data Preprocessing

DATA MANIPULATION & VISUALISATION

GUSTHI PANGESTU

D4 IT D | 3124600098





1. LOAD DATASET

Proses pembacaan file titanic.csv menggunakan `pandas.read_csv()`. Fungsi `.head()` menampilkan 5 baris awal untuk melihat struktur kolom seperti PassengerId, Survived, Pclass, Name, Sex, Age, hingga Fare.

```
01_load_dataset.py X update_nb.py 10_visualisasi_age_survived.py
jawaban > 01_load_dataset.py > ...
1 import os
2 import pandas as pd
3
4 # Load dataset
5 base_dir = os.path.dirname(os.path.abspath(__file__))
6 csv_path = os.path.join(base_dir, '..', 'data', 'titanic.csv')
7 if not os.path.exists(csv_path):
8     csv_path = 'data/titanic.csv'
9
10 dataset = pd.read_csv(csv_path)
11
12 # Tampilkan seluruh data
13 print("=== Data Titanic ===")
14 print(dataset)
15
16 # Tampilkan 5 baris teratas
17 print("\n=== 5 Baris Pertama ===")
18 print(dataset.head())
19
```

```
PS C:\Users\Gusthi Pangestu\Documents\WDM\Tugas 1> python jawaban\01_load_dataset.py
890      891      0      3 ... 7.7500 NaN      Q
[891 rows x 12 columns]

=== 5 Baris Pertama ===
   PassengerId  Survived  Pclass  ...    Fare Cabin Embarked
0             1         0       3 ...  7.2500   NaN        S
1             2         1       1 ... 71.2833   C85        C
2             3         1       3 ...  7.9250   NaN        S
3             4         1       1 ... 53.1000  C123        S
4             5         0       3 ...  8.0500   NaN        S

[5 rows x 12 columns]
```



2. DIMENSI DATASET

Atribut `.shape` digunakan untuk mengembalikan dimensi matriks data secara otomatis tanpa perlu melakukan iterasi manual:

1. Data Record (891 Baris): Merepresentasikan individu penumpang Titanic.
2. Atribut Data (12 Kolom): Memuat informasi demografi, data tiket, kabin, hingga status keselamatan (Survived).

```
02_jumlah_baris_kolom.py X 01_load_dataset.py update_nb.py 1
jawaban > 02_jumlah_baris_kolom.py > ...
1  import os
2  import pandas as pd
3
4  # Load dataset
5  base_dir = os.path.dirname(os.path.abspath(__file__))
6  csv_path = os.path.join(base_dir, '..', 'data', 'titanic.csv')
7  if not os.path.exists(csv_path):
8      csv_path = 'data/titanic.csv'
9
10 dataset = pd.read_csv(csv_path)
11
12 # Ambil jumlah baris dan kolom
13 rows, cols = dataset.shape
14
15 print(f"Jumlah Baris : {rows}")
16 print(f"Jumlah Kolom : {cols}")
17
```

```
PS C:\Users\Gusthi Pangestu\Documents\WDM\Tugas 1> python jawaban\02_jumlah_baris_kolom.py
Jumlah Baris : 891
Jumlah Kolom : 12
PS C:\Users\Gusthi Pangestu\Documents\WDM\Tugas 1> 
```





3. EKSTRAKSI KOLOM FITUR

Mengekstrak subset data baru (data) dari dataset utama menggunakan teknik indexing list kolom pada Pandas:

1. Data Demografi: Memuat kolom Name, Sex, dan Age untuk mengidentifikasi profil individu penumpang.
2. Data Sosio-Ekonomi: Memuat kolom Pclass (kelas kabin) dan Fare (harga tiket) untuk mengukur faktor ekonomi.
3. Hasil: Diperoleh DataFrame baru berukuran 891 baris × 5 kolom yang lebih ringkas dan siap diolah.

```
03_fitur_dataset.py × 02_jumlah_baris_kolom.py 01_load_dataset.py
jawaban > 03_fitur_dataset.py > ...
1 import os
2 import pandas as pd
3
4 # Load dataset
5 base_dir = os.path.dirname(os.path.abspath(__file__))
6 csv_path = os.path.join(base_dir, '..', 'data', 'titanic.csv')
7 if not os.path.exists(csv_path):
8     csv_path = 'data/titanic.csv'
9
10 dataset = pd.read_csv(csv_path)
11
12 # Ambil kolom-kolom fitur yang ditentukan
13 data = dataset[['Name', 'Sex', 'Age', 'Pclass', 'Fare']]
14
15 # Tampilkan hasil
16 print("=== Kolom Fitur (Name, Sex, Age, Pclass, Fare) ===")
17 print(data)
18 Ctrl+L for Agent
```



HASIL EKSTRAKSI KOLOM FITUR

```
● PS C:\Users\Gusthi Pangestu\Documents\WDM\Tugas 1> python jawaban\03_fitur_dataset.py  
=== Kolom Fitur (Name, Sex, Age, Pclass, Fare) ===
```

	Name	Sex	Age	Pclass	Fare
0	Braund, Mr. Owen Harris	male	22.0	3	7.2500
1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	71.2833
2	Heikkinen, Miss. Laina	female	26.0	3	7.9250
3	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	53.1000
4	Allen, Mr. William Henry	male	35.0	3	8.0500
..	...	...	...	...	...
886	Montvila, Rev. Juozas	male	27.0	2	13.0000
887	Graham, Miss. Margaret Edith	female	19.0	1	30.0000
888	Johnston, Miss. Catherine Helen "Carrie"	female	NaN	3	23.4500
889	Behr, Mr. Karl Howell	male	26.0	1	30.0000
890	Dooley, Mr. Patrick	male	32.0	3	7.7500

```
[891 rows x 5 columns]
```

```
○ PS C:\Users\Gusthi Pangestu\Documents\WDM\Tugas 1> █
```



4. EKSTRAKSI KOLOM TARGET (CLASS)

Mengambil kolom target keselamatan menggunakan perintah ***dataset['Survived']*** :

1. Berfungsi sebagai Ground Truth (label kelas) dalam tugas klasifikasi data mining.
2. Tipe Data: Data kategorik biner dengan 891 entri record.
3. Sekaligus menjadi acuan pembandingan saat mengevaluasi pengaruh lain seperti jenis kelamin, umur, dan kelas tiket.

```
04_kelas_survived.py X 03_fitur_dataset.py 02_jumlah_baris_kolom.py
jawaban > 04_kelas_survived.py > ...
1 import os
2 import pandas as pd
3
4 # Load dataset
5 base_dir = os.path.dirname(os.path.abspath(__file__))
6 csv_path = os.path.join(base_dir, '..', 'data', 'titanic.csv')
7 if not os.path.exists(csv_path):
8     csv_path = 'data/titanic.csv'
9
10 dataset = pd.read_csv(csv_path)
11
12 # Ambil kolom target kelas (Survived)
13 target_class = dataset['Survived']
14
15 # Tampilkan hasil
16 print("=== Kolom Kelas (Survived) ===")
17 print(target_class)
18 Ctrl+L for Agent
```

HASIL EKSTRAKSI KOLOM TARGET (CLASS)

```
PS C:\Users\Gusthi Pangestu\Documents\WDM\Tugas 1> python jawaban\04_kelas_survived.py
=== Kolom Kelas (Survived) ===
0      0
1      1
2      1
3      1
4      0
..
886    0
887    1
888    0
889    1
890    0
Name: Survived, Length: 891, dtype: int64
PS C:\Users\Gusthi Pangestu\Documents\WDM\Tugas 1>
```



5. FEATURE ENGINEERING: RELATIVES

Menambahkan fitur baru bernama Relatives ke dalam dataset:

- Rumus : $\text{SibSp} + \text{Parch}$
- Arti : Total kerabat/keluarga yang mendampingi penumpang di atas kapal.
- Contoh : Jika penumpang membawa 1 istri ($\text{SibSp}=1$) dan 2 anak ($\text{Parch}=2$), maka nilai Relatives = 3.

```
08_survived_per_pclass.py 07_hitung_sex.py 06_hitung_pclass.py 05
jawaban > 05_tambah_fitur_relatives.py > ...
1 import os
2 import pandas as pd
3
4 # Load dataset
5 base_dir = os.path.dirname(os.path.abspath(__file__))
6 csv_path = os.path.join(base_dir, '..', 'data', 'titanic.csv')
7 if not os.path.exists(csv_path):
8     csv_path = 'data/titanic.csv'
9
10 dataset = pd.read_csv(csv_path)
11
12 # Ambil data fitur awal
13 data = dataset[['Name', 'Sex', 'Age', 'Pclass', 'Fare']].copy()
14
15 # Tambahkan fitur Relatives (SibSp + Parch)
16 data['Relatives'] = dataset['SibSp'] + dataset['Parch']
17
18 # Tampilkan hasil
19 print("=== Data Fitur + Relatives ===")
20 print(data)
```



HASIL FEATURE ENGINEERING: RELATIVES

```
PS C:\Users\Gusthi Pangestu\Documents\WDM\Tugas 1> python jawaban\05_tambah_fitur_relatives.py
=== Data Fitur + Relatives ===
```

	Name	Sex	Age	Pclass	Fare	Relatives
0	Braund, Mr. Owen Harris	male	22.0	3	7.2500	1
1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	71.2833	1
2	Heikkinen, Miss. Laina	female	26.0	3	7.9250	0
3	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	53.1000	1
4	Allen, Mr. William Henry	male	35.0	3	8.0500	0
..	...	...	...	...	...	...
886	Montvila, Rev. Juozas	male	27.0	2	13.0000	0
887	Graham, Miss. Margaret Edith	female	19.0	1	30.0000	0
888	Johnston, Miss. Catherine Helen "Carrie"	female	NaN	3	23.4500	3
889	Behr, Mr. Karl Howell	male	26.0	1	30.0000	0
890	Dooley, Mr. Patrick	male	32.0	3	7.7500	0

```
[891 rows x 6 columns]
PS C:\Users\Gusthi Pangestu\Documents\WDM\Tugas 1> 
```



```
08_survived_per_pclass.py 07_hitung_sex.py 06_hitung_pclass.py X
jawaban > 06_hitung_pclass.py > ...
1 import os
2 import pandas as pd
3
4 # Load dataset
5 base_dir = os.path.dirname(os.path.abspath(__file__))
6 csv_path = os.path.join(base_dir, '..', 'data', 'titanic.csv')
7 if not os.path.exists(csv_path):
8     csv_path = 'data/titanic.csv'
9
10 dataset = pd.read_csv(csv_path)
11
12 # Hitung jumlah penumpang tiap kelas
13 pclass_counts = dataset['Pclass'].value_counts().sort_index()
14
15 print("=== Jumlah Penumpang per Pclass ===")
16 for pclass, count in pclass_counts.items():
17     print(f"Pclass {pclass} : {count} penumpang")
18
```

6. DISTRIBUSI PENUMPANG BERDASARKAN PCLASS

Menghitung sebaran strata sosial-ekonomi penumpang berdasarkan tiket kabin yang dibeli menggunakan ***dataset['Pclass'].value_counts().sort_index()*** untuk mengelompokkan dan mengurutkan jumlah data per kategori kelas (1, 2, dan 3).



HASIL DISTRIBUSI PENUMPANG BERDASARKAN PCLASS

```
PS C:\Users\Gusthi Pangestu\Documents\WDM\Tugas 1> python jawaban\06_hitung_pclass.py  
=== Jumlah Penumpang per Pclass ===  
Pclass 1 : 216 penumpang  
Pclass 2 : 184 penumpang  
Pclass 3 : 491 penumpang  
PS C:\Users\Gusthi Pangestu\Documents\WDM\Tugas 1> |
```

Distribusi Kelas:

- *Kelas 1: 216 orang*
- *Kelas 2: 184 orang*
- *Kelas 3: 491 orang*





7. DISTRIBUSI PENUMPANG BERDASARKAN JENIS KELAMIN

Menganalisis sebaran gender penumpang untuk memahami profil demografi kapal menggunakan Metode Ekstraksi: Mengelompokkan data biner kategori (male dan female) secara otomatis menggunakan Pandas ***value_counts()***.

```
08_survived_per_pclass.py 07_hitung_sex.py X 06_hitung_pclass.py
jawaban > 07_hitung_sex.py > ...
1 import os
2 import pandas as pd
3
4 # Load dataset
5 base_dir = os.path.dirname(os.path.abspath(__file__))
6 csv_path = os.path.join(base_dir, '..', 'data', 'titanic.csv')
7 if not os.path.exists(csv_path):
8     csv_path = 'data/titanic.csv'
9
10 dataset = pd.read_csv(csv_path)
11
12 # Hitung jumlah penumpang berdasarkan jenis kelamin
13 sex_counts = dataset['Sex'].value_counts()
14
15 print("=== Jumlah Penumpang per Sex ===")
16 for sex, count in sex_counts.items():
17     print(f"Sex '{sex}' : {count} penumpang")
18
```



HASIL DISTRIBUSI PENUMPANG BERDASARKAN JENIS KELAMIN

```
PS C:\Users\Gusthi Pangestu\Documents\WDM\Tugas 1> python jawaban\07_hitung_sex.py
=== Jumlah Penumpang per Sex ===
Sex 'male' : 577 penumpang
Sex 'female' : 314 penumpang
PS C:\Users\Gusthi Pangestu\Documents\WDM\Tugas 1> █
```

Komposisi Gender:

- *Laki-laki: 577 penumpang (64.8%)*
- *Perempuan: 314 penumpang (35.2%)*





```
08_survived_per_pclass.py × 07_hitung_sex.py 06_hitung_pclass.py 05_tambah_fitur

jawaban > 08_survived_per_pclass.py > ...
1 import os
2 import pandas as pd
3
4 # Load dataset
5 base_dir = os.path.dirname(os.path.abspath(__file__))
6 csv_path = os.path.join(base_dir, '..', 'data', 'titanic.csv')
7 if not os.path.exists(csv_path):
8     csv_path = 'data/titanic.csv'
9
10 dataset = pd.read_csv(csv_path)
11
12 # Rekap jumlah selamat & tidak selamat per Pclass
13 rekap = pd.crosstab(
14     dataset['Pclass'],
15     dataset['Survived'],
16     rownames=['Pclass'],
17     colnames=['Survived']
18 )
19 rekap.rename(columns={0: 'Tidak Selamat (0)', 1: 'Selamat (1)'}, inplace=True)
20 rekap['Total'] = rekap.sum(axis=1)
21
22 print("=== Rekap Survived per Pclass ===")
23 print(rekap)
24
```

8. ANALISIS KESELAMATAN PER PCLASS (CROSSTAB)

Menghubungkan variabel independen Pclass dengan variabel target Survived menggunakan Metode Crosstab : Menyusun tabel frekuensi 2 dimensi untuk melihat sebaran korban selamat dan meninggal di setiap kelas.

HASIL ANALISIS KESELAMATAN PER PCLASS (CROSSTAB)

```
PS C:\Users\Gusthi Pangestu\Documents\WDM\Tugas 1> python jawaban\08_survived_per_pclass.py
=== Rekap Survived per Pclass ===
Survived Tidak Selamat (0) Selamat (1) Total
Pclass
1          80          136          216
2          97           87          184
3         372          119          491
PS C:\Users\Gusthi Pangestu\Documents\WDM\Tugas 1>
```

Perbandingan Angka Keselamatan :


- *Tingkat Selamat Kelas 1 : 63.0%*
- *Tingkat Selamat Kelas 2 : 47.3%*
- *Tingkat Selamat Kelas 3 : 24.2%*

Kesimpulan : Status sosial-ekonomi penumpang berbanding lurus dengan peluang bertahan hidup pada tragedi Titanic.

```

09_visualisasi_sex_survived.py X 08_survived_per_pclass.py 07_hitung_sex.py 06_hitung
jawaban > 09_visualisasi_sex_survived.py > ...
1  import os
2  import pandas as pd
3  import matplotlib.pyplot as plt
4  import seaborn as sns
5
6  # Load dataset
7  base_dir = os.path.dirname(os.path.abspath(__file__))
8  csv_path = os.path.join(base_dir, '..', 'data', 'titanic.csv')
9  if not os.path.exists(csv_path):
10     csv_path = 'data/titanic.csv'
11
12  dataset = pd.read_csv(csv_path)
13
14  sns.set_theme(style="whitegrid")
15
16  # Visualisasi Urutan Data vs Sex
17  plt.figure(figsize=(10, 5))
18  sns.scatterplot(
19      x=dataset.index,
20      y=dataset['Sex'],
21      hue=dataset['Survived'].map({0: 'Tidak Selamat (0)', 1: 'Selamat (1)'}),
22      palette={'Tidak Selamat (0)': '#e74c3c', 'Selamat (1)': '#2ecc71'},
23      alpha=0.7,
24      s=50
25  )
26
27  plt.title('Visualisasi: Urutan Data vs Sex Berdasarkan Status Survived')
28  plt.xlabel('Urutan Data (Index)')
29  plt.ylabel('Sex')
30  plt.legend(title='Status Survived', loc='center right')
31  plt.tight_layout()
32
33  # Simpan ke folder output
34  output_dir = os.path.join(base_dir, '..', 'output')
35  os.makedirs(output_dir, exist_ok=True)
36  save_path = os.path.join(output_dir, 'visualisasi_no9_sex_survived.png')
37  plt.savefig(save_path, dpi=300)
38  print(f"Grafik disimpan di: {save_path}")
39
40  plt.show()
41

```




9. VISUALISASI: URUTAN DATA VS SEX (STATUS SURVIVED)

Menampilkan pemetaan sebaran keselamatan antara pria dan wanita menggunakan :

- Sumbu X : Indeks Urutan Data | Sumbu Y : Kategori Gender
- Warna : ● Hijau (Selamat) | ● Merah (Tidak Selamat)

HASIL VISUALISASI: URUTAN DATA VS SEX (STATUS SURVIVED)



Kesimpulan:

Terlihat disparitas yang sangat kontras di mana penumpang perempuan memiliki rasio bertahan hidup yang jauh lebih tinggi dibandingkan penumpang laki-laki.




10. VISUALISASI: URUTAN DATA VS AGE (STATUS SURVIVED)

Visualisasi sebaran umur penumpang (tanpa missing value) menggunakan :

- Metode : Scatter plot dengan filter ***dropna(subset=['Age'])***.
- Sumbu : X = Indeks Data, Y = Umur Penumpang (Tahun).
- Warna : ● Hijau (Selamat) | ● Merah (Tidak Selamat).

```
10_visualisasi_age_survived.py X 09_visualisasi_sex_survived.py 08_survived_per_pclass.py 07_hitun
jawaban > 10_visualisasi_age_survived.py > ...
1 import os
2 import pandas as pd
3 import matplotlib.pyplot as plt
4 import seaborn as sns
5
6 # Load dataset
7 base_dir = os.path.dirname(os.path.abspath(__file__))
8 csv_path = os.path.join(base_dir, '..', 'data', 'titanic.csv')
9 if not os.path.exists(csv_path):
10     csv_path = 'data/titanic.csv'
11
12 dataset = pd.read_csv(csv_path)
13
14 # Hapus data yang Age-nya bernilai NaN
15 dataset_clean = dataset.dropna(subset=['Age'])
16
17 sns.set_theme(style="whitegrid")
18
19 # Visualisasi Urutan Data vs Age
20 plt.figure(figsize=(10, 5))
21 sns.scatterplot(
22     x=dataset_clean.index,
23     y=dataset_clean['Age'],
24     hue=dataset_clean['Survived'].map({0: 'Tidak Selamat (0)', 1: 'Selamat (1)'}),
25     palette={'Tidak Selamat (0)': '#e74c3c', 'Selamat (1)': '#2ecc71'},
26     alpha=0.75,
27     s=50
28 )
29
30 plt.title('Visualisasi: Urutan Data vs Age Berdasarkan Status Survived')
31 plt.xlabel('Urutan Data (Index)')
32 plt.ylabel('Age')
33 plt.legend(title='Status Survived', loc='upper right')
34 plt.tight_layout()
35
36 # Simpan ke folder output
37 output_dir = os.path.join(base_dir, '..', 'output')
38 os.makedirs(output_dir, exist_ok=True)
39 save_path = os.path.join(output_dir, 'visualisasi_no10_age_survived.png')
40 plt.savefig(save_path, dpi=300)
41 print(f"Grafik disimpan di: {save_path}")
42
```

HASIL VISUALISASI: URUTAN DATA VS AGE (STATUS SURVIVED)



Kesimpulan:

Terlihat klaster hijau yang padat pada rentang usia anak-anak (bawah), sedangkan kelompok usia dewasa didominasi oleh titik merah.

KESIMPULAN

Berdasarkan serangkaian tahapan data preprocessing, manipulasi, dan visualisasi pada dataset Titanic, dapat disimpulkan bahwa peluang keselamatan penumpang tidak terdistribusi secara acak, melainkan sangat dipengaruhi oleh faktor demografi (gender & usia) serta faktor sosio-ekonomi (kelas tiket).



Prioritas Penyelamatan (Gender & Usia)

- Penumpang perempuan memiliki tingkat keselamatan yang jauh lebih tinggi dibandingkan laki-laki.
- Penumpang kelompok anak-anak (<10 tahun) mendapatkan prioritas evakuasi tertinggi.
- Hal ini membuktikan dilakukannya penerapan protokol penyelamatan laut "Women and children first".



Pengaruh Kelas Tiket & Data Preprocessing

- Penumpang Kelas 1 memiliki tingkat keselamatan tertinggi (>60%), berbanding terbalik dengan Kelas 3 (<25%).
- Pembersihan data (drop missing value) dan pembuatan fitur baru (Relatives) terbukti mempermudah identifikasi pola keselamatan penumpang secara akurat.



TUGAS M2 - DATA MINING

TERIMA KASIH

You can access my GitHub repository for the source code :

https://github.com/GusthiPangestu1906/WDM.1-Data_Preprocessing.git